


11장 운영 구조 및 모니터링

11.4 시나리오 — 전력 과부하(overload)

전력 더미가 과부하 패턴을 1초 주기로 전송하면 5축 양상블 AI가 추론을 실행하고 알람을 Redis Stream에 적재한다. alarm_flush_loop가 이를 소비해 WebSocket으로 브로드캐스트하며, 이 전체 구간의 지연이 E2E latency로 측정된다.



11.4.1 전력 AI 추론 실행 빈도 diconai-power-ai

데이터가 수신될 때마다 AI 추론이 실제로 실행되고 있는지 확인하는 패널이다. 0으로 떨어지면 FastAPI 장애 또는 모델 로드 실패를 의미한다.




[테스트 결과] 5분 rate(req/s), 더미 시작 후 0→3 상승

메트릭	process_anomaly_inference() 호출 횟수
집계	5분 rate (req/s)
측정값	더미 시작 전 0 → 약 3 req/s 상승 후 유지
판정	✅ AI 추론이 데이터 수신과 1:1 연동 확인. 0이면 FastAPI 또는 모델 로드 장애

[전력 AI 추론 실행 빈도 메트릭 명세]

11.4.2 전력 AI 알람 발화 횟수 diconai-power-ai

5축 양상블 중 어떤 알고리즘이 실제로 알람을 발화했는지 확인하는 패널이다. ARIMA·IF·combined 3개 라인이 각각 독립적으로 계단형으로 올라가야 양상블이 정상 동작하는 것이다.




[테스트 결과] algorithm_source별 누적 계단형 발화 횟수

메트릭	POWER_AI_ALARM_FIRED_TOTAL
레이블	algorithm_source (arima / isolation_forest / combined)
측정값	overload 시작 후 3개 라인 모두 계단형 상승. arima 발화 횟수 최다
판정	✅ 5축 양상블 정상 동작 확인. ARIMA가 IF보다 높은 것은 지속 drift를 trend break로 먼저 감지하는 특성

[전력 AI 알람 발화 횟수 메트릭 명세]

11.4.3 전력 AI vs 임계치 발화 비율 diconai-power-ai

AI가 임계치보다 먼저 알람을 발화하고 있는지, 그리고 AI mute로 임계치 알람이 제대로 억제되고 있는지를 동시에 검증하는 패널이다. AI 사전 감지 라인이 존재하는 것 자체가 "임계치 초과 전 경보 발령"이라는 설계 목표 달성의 직접 증거다.



[테스트 결과] AI 발화·AI 사전 감지·임계치 발화 danger/warning 4개 라인 비율 비교


라인	측정값
AI 발화 (warning+danger)	지속 상승
AI 사전 감지 (predict_warn)	지속 상승
임계치 발화 danger	0 유지
임계치 발화 warning	0 유지

판정	✅ AI mute 활성화로 임계치 알람 완전 억제 확인. AI 사전 감지 라인 존재 = 임계치 초과 이전 경보 발령 설계 목표 달성 직접 증거
----	---

[테스트 결과 표]

11.4.4 E2E 알람 latency diconai-alarm

센서 수신 시각(ingress_ts)부터 WebSocket 브로드캐스트까지 전체 구간 지연을 측정한다. danger가 warning보다 지연이 큰 이유는 decide_alarm() 6매트릭스 결정과 DRF AlarmRecord 생성 후 event_id 보강(timeout 500ms) 과정이 포함되기 때문이다.



[테스트 결과] e2e_alarm_latency_seconds — danger/warning 분리,

지표	측정값	SLO
danger p99	930 ~ 960 ms	—
danger p95	730 ~ 860 ms	≤ 1,500 ms ✅
warning p95	430 ms	—

[E2E 알람메트릭 명세]